

1주차

항목	적을 것
[1] loss 곡선	어떤 모양이었나. 숫자 두세 개만 적어도 됩니다
[2] 생성 결과	마지막에 출력된 문장이 어땠나
[3] 이상한 점	loss와 생성 결과가 서로 다른 이야기를 하고 있지 않은가
[4] 걸리는 테스트	실패한 테스트 이름 하나와, 왜 눈에 걸렸는지
[5] 가설	뭐가 문제일 것 같나. 틀려도 됩니다

1. loss 곡선

step	train	val → 이게 loss?
0	3.3821	3.3747
50	0.1171	0.1164
200	0.0143	0.0145
400	0.0046	0.0047
500	0.0032	0.0032

2. 생성 결과

the cat .aakrbxlilniabhe gstuptobcox gs icn
tocjlficaugkjviu ff lyddlycmraf
vjbuitrslmiteomp lfrkjnn agfboh g bixcekkhpoph stvl

3. 이상한 점

step이 0일 때는 train과 val이 3.3이상이었는데 step50때 급감하더니 그 뒤로는 계속 약간씩 감소하는 추세를 보임. loss가 0에 가까운 정도가 나왔으면 생성 결과가 영어 사전에 있는 단어이거나 문장이어야 할 텐데 알 수 없는 알파벳의 연속이 나오게 됨.

4. 걸리는 테스트

```
collected 7 items / 1 deselected / 6 selected

test_gpt.py::test_layernorm_normalizes_each_token FAILED [ 16%]
test_gpt.py::test_layernorm_is_independent_across_batch FAILED [ 33%]
test_gpt.py::test_attention_weights_sum_to_one FAILED [ 50%]
test_gpt.py::test_attention_is_causal FAILED [ 66%]
test_gpt.py::test_positional_embedding_affects_output FAILED [ 83%]
test_gpt.py::test_targets_are_shifted_by_one FAILED [100%]
```

엥 다 실패했다 이게 맞는지 모르겠지만 일단 하나를 고르자

→ test_attention_is_causal

```
_____ test_attention_is_causal _____

def test_attention_is_causal():
    """t 시점은 t보다 뒤의 토큰을 볼 수 없다. 미래 가중치는 정확히 0이다."""
    model = make_model()
    idx = torch.randint(0, VOCAB, (2, BLOCK))
    att = attention_weights(model, idx)

    future = att.triu(diagonal=1)
    > assert future.abs().max() == 0, \
        f"미래 토큰에 가중치가 실림 (최대 {future.abs().max():.4f})"
E   AssertionError: 미래 토큰에 가중치가 실림 (최대 0.0695)
E   assert tensor(0.0695, grad_fn=<MaxBackward1>) == 0
```

미래 가중치가 정확히 0이라고 했는데 빨간 줄 첫 번째를 보면 미래 토큰에 가중치가 실림 (최대 0.0695)이라고 나와있어서 눈에 걸렸다. 사실 뭘 말인지 하나도 모르겠다

5. 가설

과적합?